# Indexe im Praxis

# Indexe

- Ein Index = eine Struktur auf Platte, die einer Tabelle oder Sicht zugeordnet ist, um die Tupel in der Tabelle oder Sicht schneller abzurufen

- Gute Indexierung → schnelle Applikation
- Schlechte Indexierung → verlangsamt das ganze SQL Server

# Syntax

```
CREATE [ UNIQUE ] [ CLUSTERED | NONCLUSTERED ]
INDEX index_name
ON <object> (column [ ASC | DESC ] [ ,...n ] )
[ INCLUDE (column_name [ ,...n ] ) ]
[ WHERE <filter_predicate> ]
[ WITH ( <relational_index_option> [ ,...n ] ) ]
```

# Überprüfe existierende Indexe

- Es gibt viele Möglichkeiten:
  - Gespeicherte Prozedur ***sp_helpindex***

```
EXEC sys.sp_helpindex @objname = N’Tabelle1’
```

  - System Tabellen und Sichte, wie zum Beispiel:

```
SELECT *
FROM sys.indexes
WHERE object_id = OBJECT_ID(‘Tabelle1')
```

# Eigenschaften eines Index

- Geclustert vs. Nicht-geclustert
- Unique(eindeutig) vs. Nonunique
- Mit einfachem vs. zusammengesetztem Schlüssel
- Aufsteigender oder absteigender Reihenfolge auf die Spalte des Index
- Für die ganze Tabelle vs. Gefiltert für nicht-geclusterte Indexe

# Geclusterte und Nicht-Geclusterte Indexe

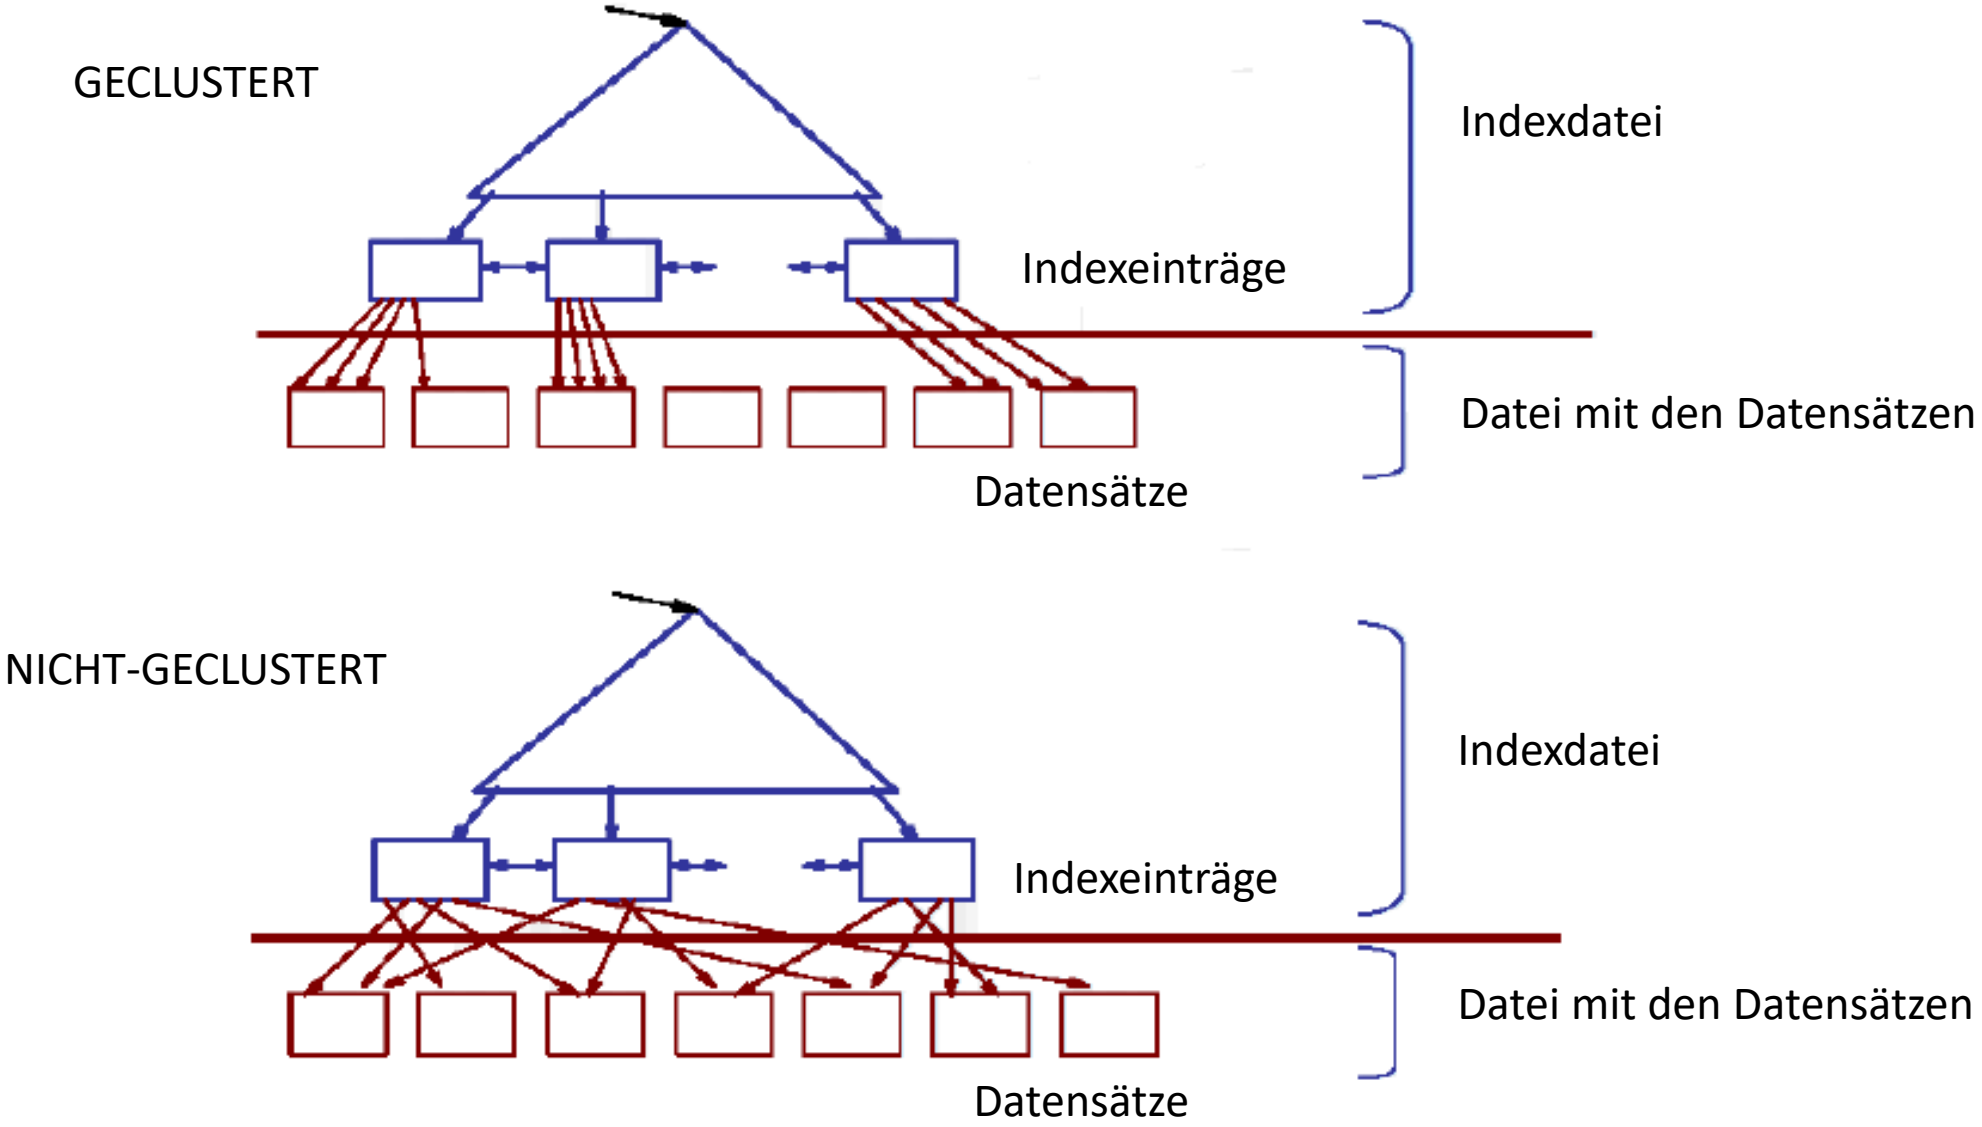

# Geclusterte vs. Nicht-geclusterte Indexe

- Geclusterte Indexe: die Tupel in der Tabelle werden nach dem Suchschlüssel sortiert und gespeichert

```
CREATE CLUSTERED INDEX Index_Name
ON Schema.TableName(Column);
```

- Nicht-geclusterte Indexe: Suchschlüsselwerte und Zeiger zu den Tupeln in der Datei (die ein Haufendatei oder sogar ein geclusterter Index sein kann)

```
CREATE INDEX Index_Name
ON Schema.TableName(Column);
```

# Geclusterte vs. Nicht-geclusterte Indexe

- Die Datenseiten eines geclusterten Index werden immer alle Spalten in der Tabelle enthalten
- Es gibt nur ein geclusterter Index per Tabelle
- SQL Server unterstützt bis zu 999 nicht-geclusterte Indexe für eine Tabelle
- Ein Suchschlüssel für ein Index (geclustert oder nicht-geclustert) kann maximal 16 Spalten und 900 Bytes enthalten

# Geclusterte Indexe

- Können für Anfragen, die oft vorkommen, benutzt werden
- Sind effizient für Bereichsanfragen

- Geclusterte Indexe sind nicht gut für:
  - Suchschlüssel, die oft geändert werden
  - Große Suchschlüssel

# Geclusterte Indexe

- Werden als B-Bäume organisiert

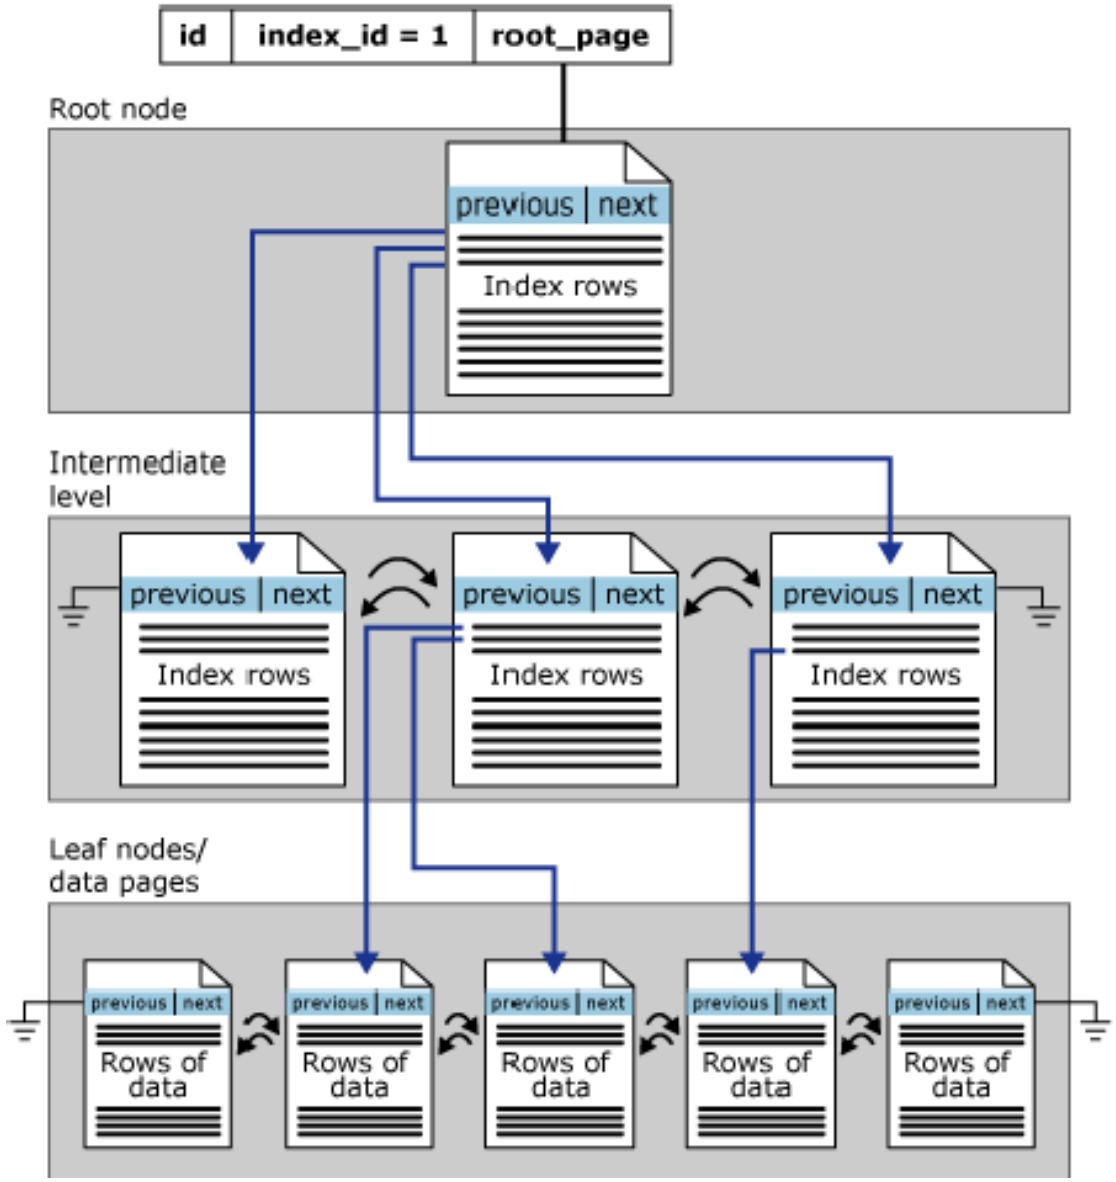

# Geclusterte vs. Nicht-geclusterte Indexe

- Wenn man ein Primärschlüssel für eine Tabelle erstellt und:
  - kein geclusterter Index wurde definiert
  - kein nicht-geclusterter Index wurde erstellt

  → ein eindeutiger geclusterter Index wird erstellt

- Wenn der Index die gesamte Abfrage deckt (alle nötige Spalten enthält), dann bezeichnet man den Index auch als *Covering Index*

# Schlüssel vs. Nichtschlüssel Indexspalten

- Schlüssel Indexspalten: die Spalten, die in dem Suchschlüssel des Index enthalten sind
- Nichtschlüssel Indexspalten: Spalten, die in dem INCLUDE Klausel enthalten sind
  - Diese sind Spalten, die nicht Teil des Suchschlüssels sind, aber die wir vielleicht in Abfragen brauchen werden

```
CREATE INDEX Index_Name
ON Schema.TableName(Column)
INCLUDE (ColumnA, ColumnB);
```

# Schlüssel vs. Nichtschlüssel Indexspalten

- Vorteile für das Benutzen der Nichtschlüssel Indexspalten:
  - Man kann auf diese Spalten mit einem Indexscan zugreifen (obwohl die Spalten nicht Teil des Suchschlüssels sind) ; d.h. man kann ein ***Key Lookup*** vermeiden
  - Hier werden auch Datentypen erlaubt, die bei dem Suchschlüssel nicht erlaubt sind ( z.B. text, ntext, image)
  - Nichtschlüssel Indexspalten zählen nicht für die 900 Byte Limit (in SQL Server) für den Suchschlüssel

# Eindeutige Indexe

- Ein eindeutiger (unique) Index versichert, dass der Suchschlüssel des Index keine Duplikate enthält
- Ein eindeutiger Index zu erstellen, macht nur Sinn, wenn wir wissen, dass die Werte der Suchschlüssel eindeutig sind
- Die Eindeutigkeit ist eine wichtige Information für den Anfrageoptimierer

# SQL Indexe - Beispiel

- Erstelle einen Index für die Tabelle `Student` auf das Attribut `ID`

```
CREATE UNIQUE INDEX idxStudent ON Student(ID)
```

- `UNIQUE` versichert, dass die Werte des Attributes `ID` in der Tabelle (und in dem Index) eindeutig sind
- Wenn das Attribut `ID` nicht eindeutig ist, dann wird bei dem Erstellen des Index eine Fehlermeldung ausgegeben

# Gefilterte Indexe

- Gefilterte Indexe: ein optimierter nicht-geclusterter Index, besonders geeignet für Anfragen, die Daten aus einer gut definierten Teilmenge von Daten selektiert

```
CREATE NONCLUSTERED INDEX FI_EndDate ON
Products (ProductID, EndDate)
WHERE EndDate IS NOT NULL ;
GO
```

- Verbesserte Anfrage Performanz
- Reduziert die Kosten für die Erhaltung des Index (Index maintenance)
- Reduziert die Speicherkosten des Index

# Gefilterte Indexe

- Um sicher zu sein, dass ein bestimmter Index benutzt wird:

```
SELECT ProductID, EndDate
FROM Products
WITH ( INDEX (FI_EndDate ) )
WHERE EndDate IN ('20000825', '20000908');
```

Aufpassen! Das wird normalerweise für Debugging benutzt, aber ansonsten benutzen wir das nicht, der Optimierer wählt selber den besten Ausführungsplan.

Bemerkung. In der Laboraufgabe ist es nicht erlaubt, das zu benutzen!

# Index Entwurf

- Man muss die Eigenschaften der Datenbank verstehen
  - OLTP -Online Transaction Processing
    - Bei OLTP wiederholen sich die Datenbankprozesse ständig, sind strukturiert und bestehen aus isolierten, atomaren Transaktionen
    - Anwendungsbereich: Administrationssysteme
  - OLAP -Online Analytical Processing
    - Analyseprozesse auf Unternehmensdaten interaktiv („Online“) durchzuführen
    - Die historische, aggregierte Information steht im Vordergrund
    - Zugriff erfolgt meist nur lesend
    - Anwendungsbereich: Data Warehouse Systeme
- Man muss die Eigenschaften der häufigsten Anfragen verstehen
- Man muss die Eigenschaften der Spalten verstehen, die in den Anfragen benutzt werden
- Man muss den optimalen Speicherort bestimmen

# Allgemeine Index Entwurf Guidelines

- Datenbank Überlegungen:
  - Zu viele Indexe auf eine Tabelle beeinflussen die Performance folgender Anweisungen: INSERT, UPDATE, DELETE, MERGE
  - Die Indexierung der kleinen Tabellen könnte vielleicht **nicht** optimal sein
  - Die Indexierung der Sichten (Views) ist nützlich, wenn die Sichten Tabellen Joins enthalten

# Allgemeine Index Entwurf Guidelines

- Anfragen Überlegungen:
  - Erstelle nicht-geclusterten Indexe für Spalten, die oft in WHERE und JOIN Klauseln benutzt werden
  - Covering Indexe können die Effizienz verbessern
  - Schreibe Anfragen, die **so viele wie möglich Tupeln in derselben Anweisung einfügt oder ändert**

# Allgemeine Index Entwurf Guidelines

- Spalten Überlegungen:
  - Die **Länge des Suchschlüssels** für einen geclusterten Index soll „klein“ sein
  - Es ist besser **geclusterte Indexe auf eindeutige/ nicht-NULL Spalten** zu erstellen
  - Spalten mit dem Datentyp **ntext, text, image, varchar(MAX), nvarchar(MAX), varbinary(MAX)** können nicht in dem Suchschlüssel des Index enthalten sein
  - Bestimme ob die Spalte **eindeutig** ist oder nicht
  - Bestimme die **Verteilung** der Werte in der Spalte (vermeide Indexe auf Spalten mit einem sehr kleinen Wertebereich) – benutze **gefilterte** Indexe
  - Bestimme die **Reihenfolge der Spalten** für einen Index mit zusammengesetztem Suchschlüssel

  Spalten, die in Bedingungen mit “=“, “<”, “>” oder BETWEEN vorkommen, sollen als erste positioniert werden. Der Rest der Spalten soll man folgendermaßen ordnen: von dem größten Wertebreich zu dem kleinsten Wertebereich

# Index Deaktivieren

```
ALTER INDEX IX_Address_StateProvinceID
ON Person DISABLE
```

# Index Deaktivieren

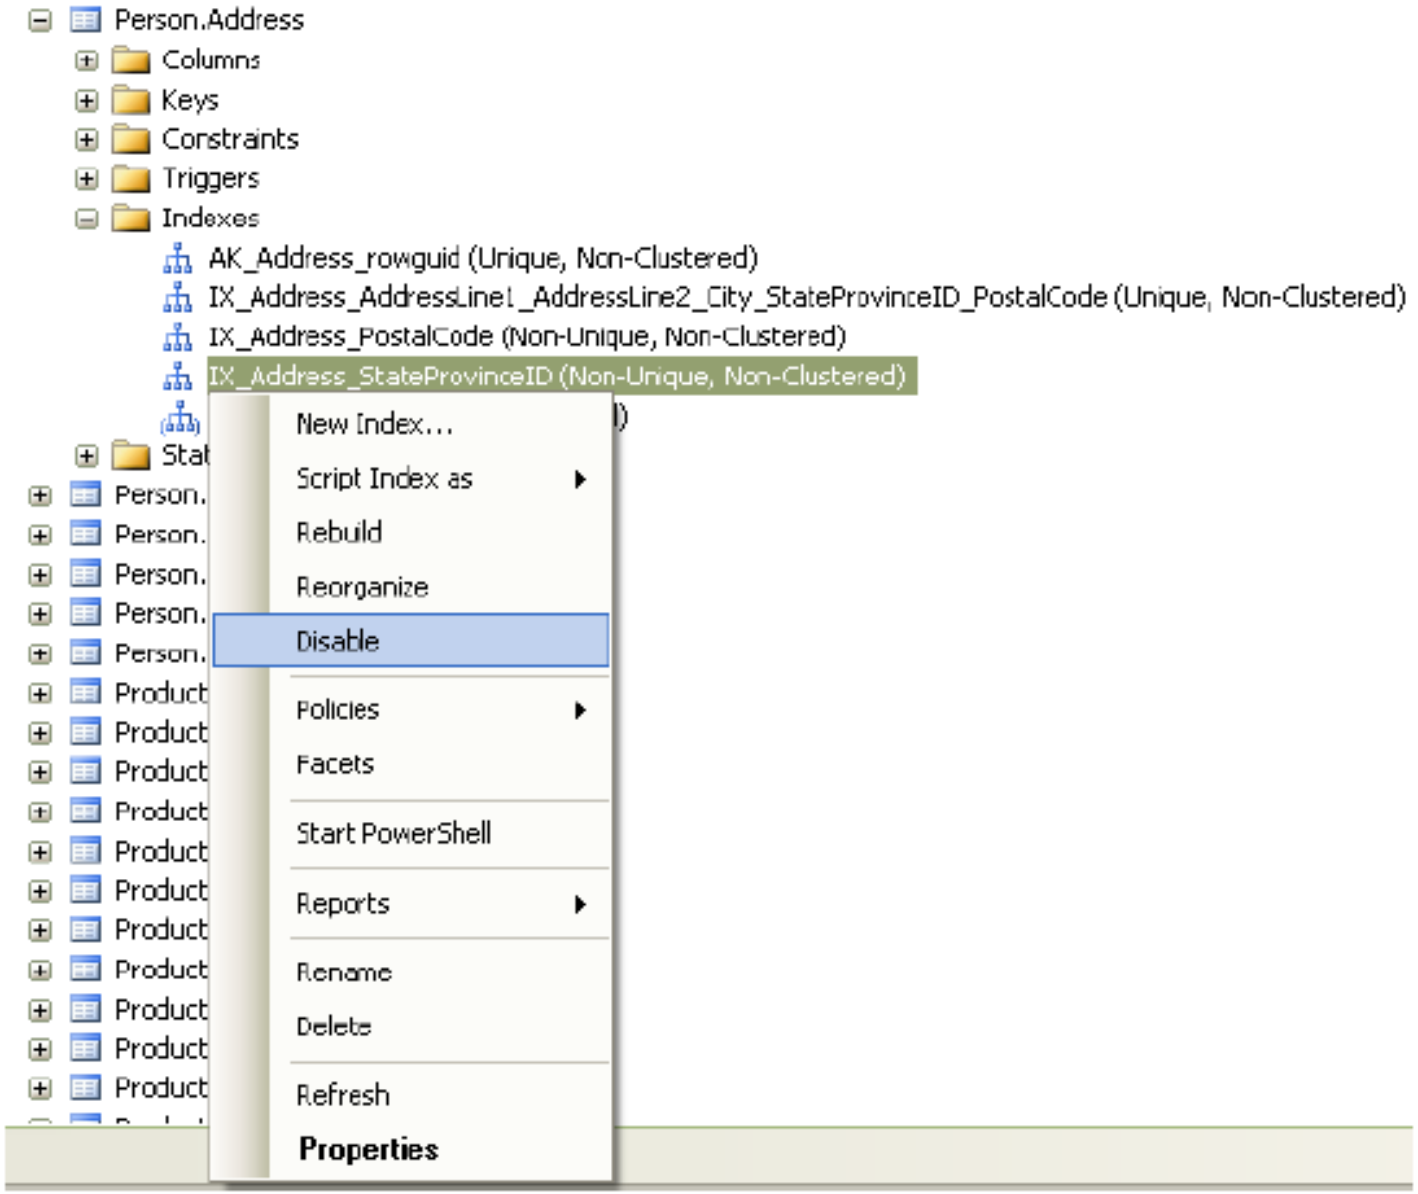

# Index Properties

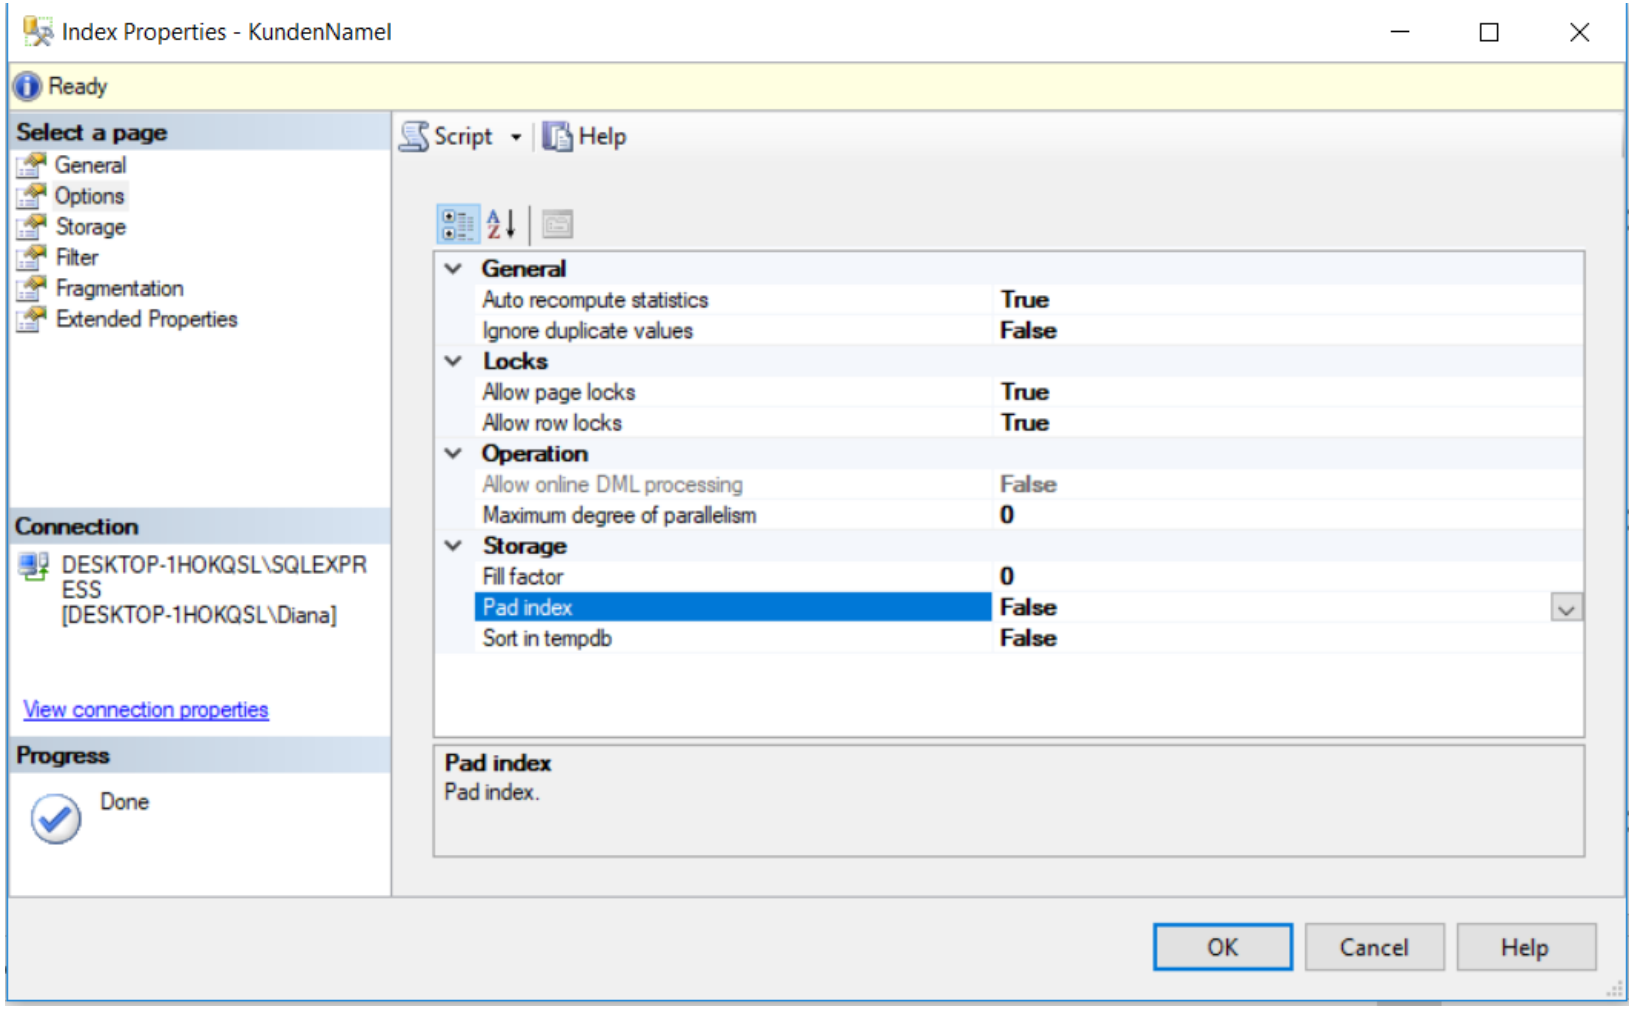


- FILL FACTOR – für die Blätter
- PAD_INDEX ON heißt "Apply FILLFACTOR to all layers"
- Mehrere Informationen: https://technet.microsoft.com/en-us/library/ms186872(v=sql.105).aspx

# Index Aktivieren

```
ALTER INDEX IX_Address_StateProvinceID
ON Person REBUILD
```

# Indexe für Löschen (DELETE)

- Beim DELETE:
  - SQL Server sucht nach abhängigen Zeilen, indem alle Fremdschlüssel überprüft werden
  - Er sucht also in allen zusammenhängenden Tabellen:
    - Falls es einen Index gibt, dann benutzt SQL Server den Index, um in diesen Tabellen Daten zu suchen
    - Falls es keinen Index gibt, dann muss SQL Server die ganze Tabelle scanen, um Daten zu suchen
  - DELETEs können sehr langsam sein, wenn es keinen Index gibt für die Fremdschlüssel

# Indizierten Sichten

- Anforderungen:
  - Die SELECT Klausel darf nicht andere Sichten benutzen
  - Die Sichtdefinition muss *deterministisch* sein (Eine Sicht ist deterministisch, wenn alle Ausdrücke in der Auswahlliste sowie die WHERE-Klausel und die GROUP BY-Klausel deterministisch sind – geben stets dasselbe Ergebnis zurück, für dasselbe Input; z.B. GETDATE ist nicht deterministisch)
  - AVG, MIN, MAX, STDEV, STDEVP, VAR (die letzten drei sind statistische Funktionen)
  - SELECT Klausel muss keine Unterabfragen, Outer Joins, EXCEPT, INTERSECT, TOP, UNION, ORDER BY, DISTINCT, ... enthalten

# Columnstore Indexe

- Stellt den Standard für das Speichern und Abfragen großer Faktentabellen im Data Warehousing dar (read-only Tabellen)
- Verwendet spaltenbasierte Datenspeicherung und Abfragenverarbeitung
- Bis zu 10x höhere Abfrageleistung im Vergleich zu der zeilenorientierten Speicherung
- Bis zu 10x Datenkomprimierung im Vergleich zu der unkomprimierten Datenvolumen
- Dieselbe Tabelle kann einen zeilenorientierten und einen spaltenorientierten Index haben → der Abfrageoptimierer entscheidet welchen Index er braucht
- Für mehrere Unterschiede zwischen Columnstore und Rowstore Indexe: http://www.sqlservercentral.com/articles/ColumnStore+Index/125264/

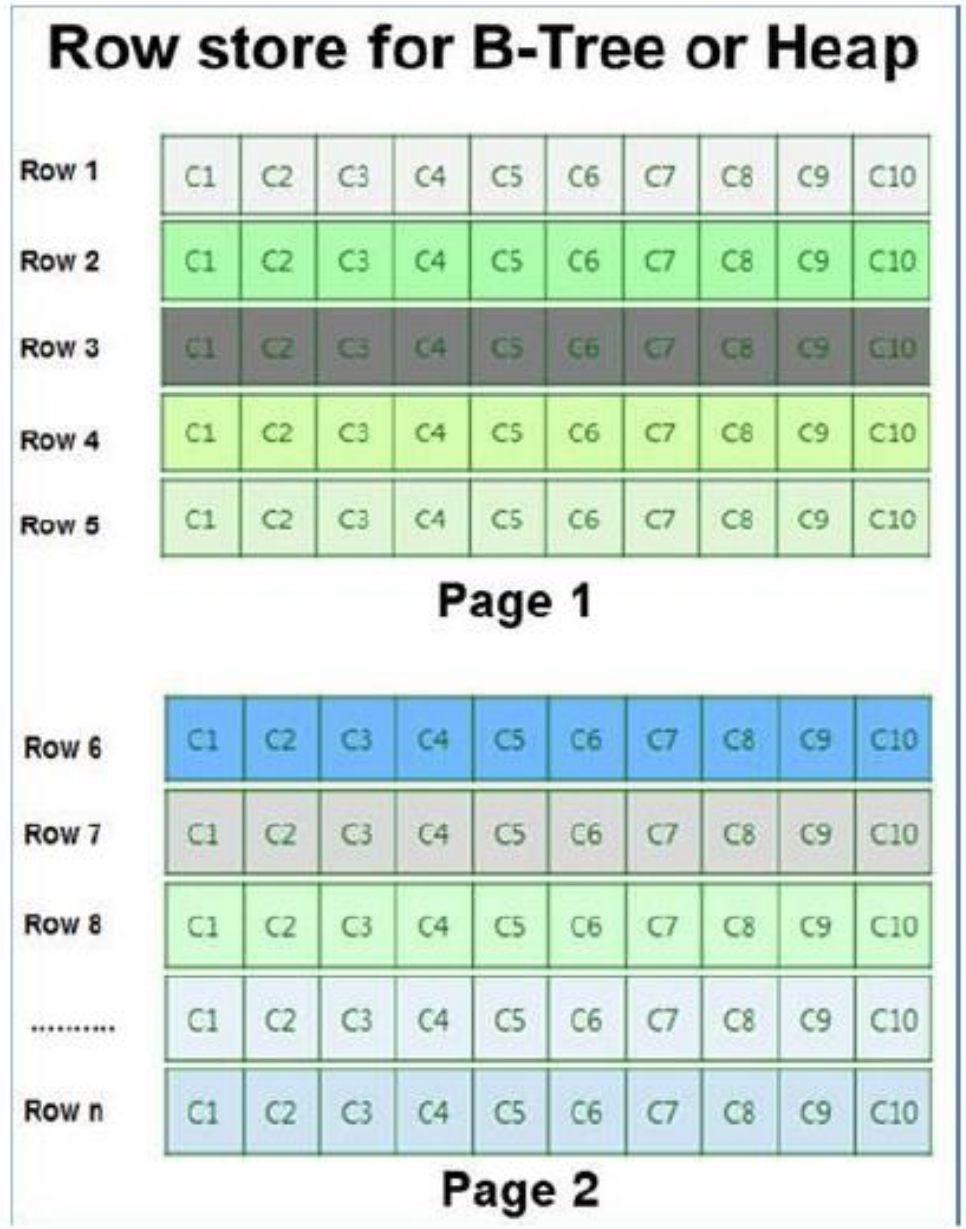
Row store for B-Tree or Heap
Row 1
Row 2
Row 3
Row 4
Row 5
C1 C2 C3 C4 C5 C6 C7 C8 C9 C10
Page 1
Row 6
Row 7
Row 8
.....
Row n
C1 C2 C3 C4 C5 C6 C7 C8 C9 C10
Page 2

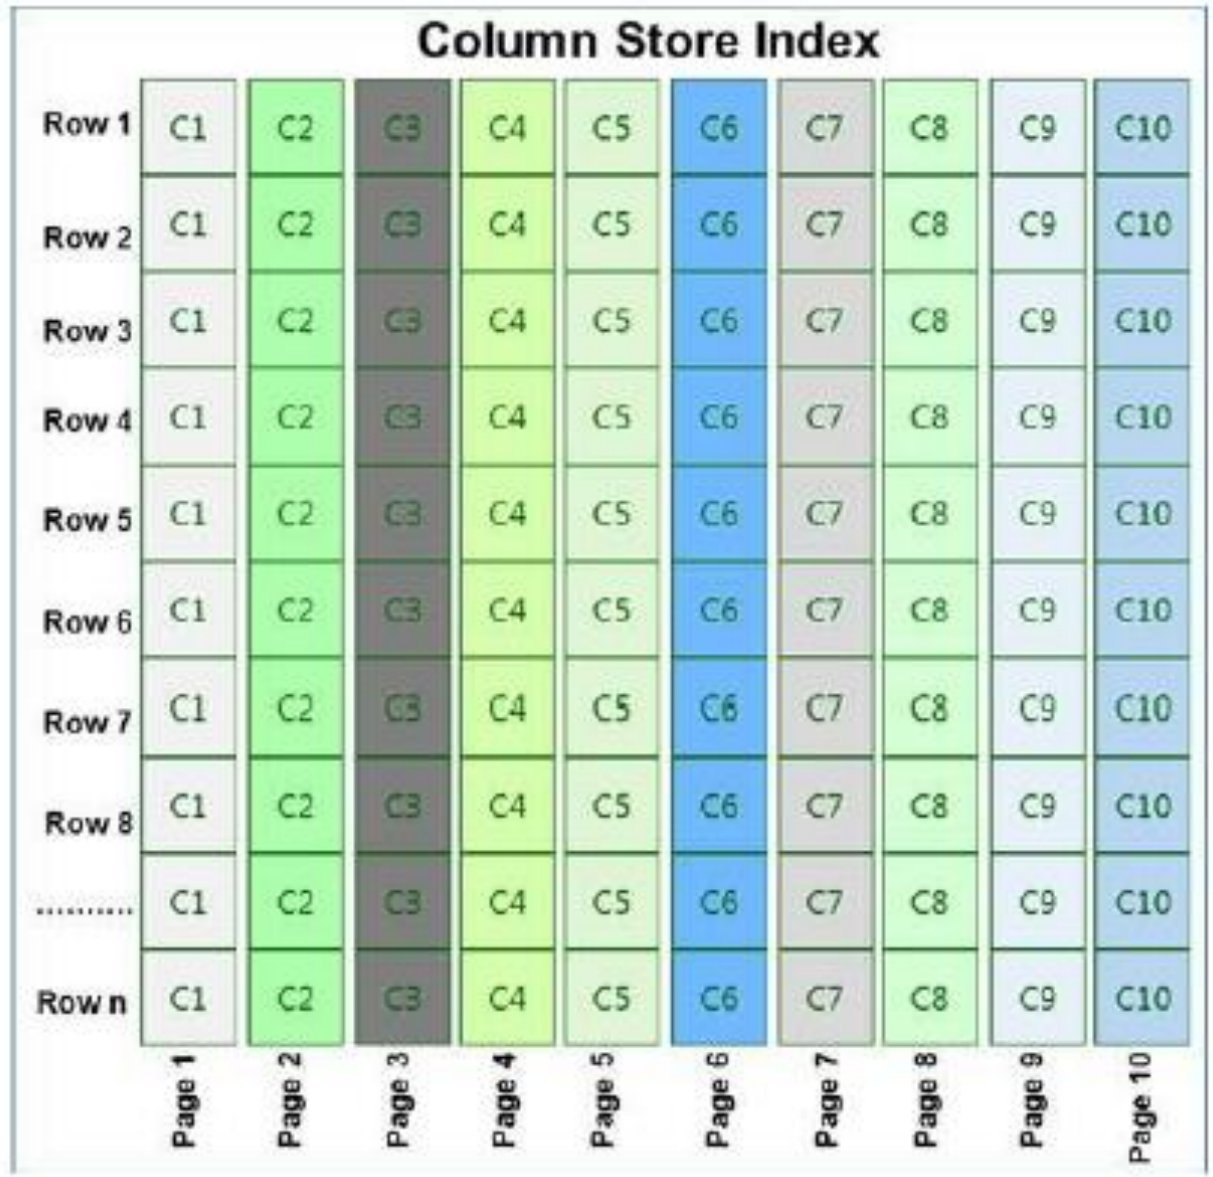
Column Store Index
Row 1
Row 2
Row 3
Row 4
Row 5
Row 6
Row 7
Row 8
.....
Row n
C1
C2
C3
C4
C5
C6
C7
C8
C9
C10
Page 1
Page 2
Page 3
Page 4
Page 5
Page 6
Page 7
Page 8
Page 9
Page 10

# Regeln für Indexierung

- Jede Tabelle sollte einen geclusterten Index haben mit folgenden Eigenschaften:
  - (idealerweise) klein,
  - selektiv (eindeutig oder „fast“ eindeutig),
  - immer aufsteigend (wähle ein Suchschlüssel, der für neue Tupeln immer größer wird – z.B. Automatisch inkrementierter Id) und
  - Statisch – ändert sich nicht viel

  → eine Tabelle ohne einen geclusterten Index heißt Haufendatei (heap)
- Erstelle nicht-geclusterte Indexe für Fremdschlüsseln
- Erstelle nicht-geclusterte Indexe on Spalten, die oft in WHERE Klauseln vorkommen

# Regeln für Indexierung

- Es ist **KEIN** guter Praxis, einen Index mit einfachem Schlüssel für jede Spalte in der Tabelle zu erstellen → dann wird es zu viele Indexe geben, nicht effizient
- Bei Indexen mit zusammengesetzten Schlüsseln, ordne die Spalten so, dass die am meisten selektiven (→ am nähesten zu Eindeutigkeit) die ersten sind
- Für die Abfragen, die am meisten vorkommen, erstelle covering, nicht-geclusterte Indexe

# Indexfragmentierung

- **Interne Fragmentierung**: wenn es freien Platz gibt zwischen Datensätze in einer Seite
  - Der freie Platz verursacht schlechte Cache Ausnutzung und dadurch mehrere I/O Operationen
- **Externe Fragmentierung**: wenn die Seiten auf die Platte nicht in aufeinanderfolgende Reihenfolge gespeichert sind (bzgl. Der Sortierungsreihenfolge)
- **Logische Fragmentierung**: wenn die Blattseiten eines Heaps/Index nicht ordnungsgemäß sortiert sind

# Indexfragmentierung

- `sys.dm_db_index_physical_stats`
  - `avg_fragmentation_in_percent`: durchschnittlicher Prozentsatz der logischen Fragmentierung (falsche Reihenfolge der Seiten in einem Index).
  - `avg_page_space_used_in_percent`: durchschnittlicher Prozentsatz des auf allen Seiten verwendeten verfügbaren Datenspeicherplatzes.

# Beheben der Fragmentierung

- Für Haufendateien :
  - Erstelle einen geclusterten Index: sortiere die Tupel in einer bestimmten Reihenfolge und speichere die Seiten aufeinanderfolgend auf die Platte
- Für Indexe:
  - Durch Neuorganisieren oder Neuerstellen des Index
  - `avg_fragmentation_in_percent:`
    - >5% und < 30% → `ALTER INDEX REORGANIZE`
      - Die Blätterseiten des Index werden in einer logischen Reihenfolge sortiert und reorganisiert
    - > 30% → `ALTER INDEX REBUILD`
      - In diesem Fall können wir den Index auch löschen und neu erstellen